

Corso di Laurea in Ingegneria e Scienze Informatiche

**Generazione automatica di dataset
text-to-SPARQL per fine-tuning di
LLM su knowledge graph
clinico-oncologico**

Tesi di laurea in:
PROGRAMMAZIONE

Relatore

Prof.ssa Antonella Carbonaro

Candidato

Matteo Tonelli

Abstract

Contents

Abstract	iii
1 Introduzione	1
2 Background	3
3 Analisi	5
3.1 Obiettivi	5
3.2 Vincoli	6
3.3 Requisiti funzionali	7
3.4 Requisiti non funzionali	7
4 Progettazione	9
4.1 Analisi dei problemi	9
4.2 Design del generatore	10
4.2.1 Modello del dominio	10
4.2.2 Sistema dei parametri	13
4.2.3 Meccanismo di estensione	14
4.3 Design dell'augmentation	15
4.3.1 Mascheramento dei valori letterali	15
4.3.2 Generazione iterativa e validazione	16
4.3.3 Varietà stilistica	17
5 Implementazione	19
6 Valutazione	21
7 Conclusioni e sviluppi futuri	23

CONTENTS

List of Figures

4.1	Modello di dominio semplificato: Patient come nodo centrale, con una classe rappresentativa per ciascuno dei sei gruppi di priorità . .	12
4.2	Modello esemplificativo dei parametri filtrabili	13

LIST OF FIGURES

List of Listings

LIST OF LISTINGS

Chapter 1

Introduzione

Structure of the Thesis

Chapter 2

Background

Questo capitolo introduce le tecnologie e i concetti fondamentali necessari per la comprensione del contributo della tesi. Nelle sezioni successive viene presentato il Cancer Virtual Lab, il progetto nel cui ambito si colloca il lavoro descritto, seguito dai concetti di knowledge graph e SPARQL, dal problema del text-to-SPARQL e dalle sue difficoltà specifiche nel dominio clinico, dai lavori correlati sulla costruzione di dataset per questo compito e, infine, dai rischi specifici dell’augmentation testuale basata su modelli linguistici di grandi dimensioni.

Chapter 3

Analisi

3.1 Obiettivi

L'obiettivo primario del progetto è la creazione di una pipeline in grado di costruire di un dataset annotato per il fine-tuning di un modello linguistico di dimensioni contenute, destinato alla traduzione di domande in linguaggio naturale in query SPARQL da eseguire sul knowledge graph del Cancer Virtual Lab. Da questo obiettivo generale derivano quattro obiettivi più specifici, che hanno guidato le scelte progettuali descritte nei capitoli successivi.

- O1** *Copertura selettiva ed estendibilità.* Il dataset deve coprire le parti dello schema del knowledge graph più rilevanti per l'applicazione, senza richiedere la copertura completa dello schema. Il sistema deve inoltre permettere di estendere progressivamente questa copertura aggiungendo nuove classi e relazioni, senza richiedere una riprogettazione del generatore.
- O2** *Varietà linguistica autentica.* Le domande generate devono presentare una varietà linguistica sufficiente a evitare formulazioni ripetitive o riconducibili a un unico template, mantenendo invariato il significato espresso dalla query sottostante.
- O3** *Tracciabilità completa.* Ogni domanda generata deve essere associata in modo univoco alla query SPARQL da cui deriva. L'associazione tra do-

manda e query deve essere quindi conservata esplicitamente, così da rendere verificabile ogni coppia utilizzata nel dataset.

- O4** *Volume di dati adeguato al fine-tuning.* Il dataset deve contenere un numero di esempi sufficiente per supportare il fine-tuning del modello linguistico considerato e deve garantire una copertura adeguata delle diverse tipologie di query previste.

3.2 Vincoli

Il progetto è stato condotto sotto un insieme di vincoli tecnici che ne hanno influenzato le scelte architetturali, descritte nel dettaglio nei capitoli successivi.

- V1** *Compatibilità con uno schema esistente e non modificabile.* Il sistema deve generare query conformi allo schema dell'ontologia del Cancer Virtual Lab, preesistente al progetto e non alterabile nel suo ambito. Nomi di classi, proprietà e relazioni sono vincoli esterni, non negoziabili in funzione di una generazione più semplice o di una copertura più ampia.
- V2** *Trattamento di dati clinici sensibili.* I valori coinvolti nelle query come identificativi di pazienti, codici di classificazione clinica o date sono dati clinici il cui significato deve rimanere verificabile e inalterato in ogni fase del processo. Questo vincolo esclude, inoltre, l'invio di tali dati a servizi esterni non controllati, imponendo l'esecuzione locale di qualunque componente del sistema che vi acceda.
- V3** *Capacità limitata del modello linguistico impiegato.* A causa del vincolo sull'esecuzione locale imposto da V2, il sistema potrà sfruttare solo modelli di dimensioni molto contenute, non potendo quindi fare affidamento sulla correttezza semantica spontanea dell'output prodotto, e richiede un meccanismo di validazione esplicito e indipendente dal modello stesso.

3.3 Requisiti funzionali

I requisiti funzionali descrivono cosa il sistema deve produrre, indipendentemente da come tale produzione venga realizzata.

- RF1** *Generazione di coppie prompt-query.* Il sistema deve generare coppie costituite da una query SPARQL sintatticamente valida e da un prompt in linguaggio naturale corrispondente, a partire dallo schema del knowledge graph.
- RF2** *Produzione di varianti multiple.* Il sistema deve produrre, per ciascuna coppia generata, un numero variabile di varianti parafrasate del medesimo prompt, preservando invariata la query associata.
- RF3** *Preservazione dei valori letterali.* Il sistema deve garantire, in ciascuna variante parafrasata, la presenza dei valori letterali presenti nella query, quali identificativi di pazienti, codici di classificazione clinica o date, nella loro forma esatta o in una forma alternativa verificabile.
- RF4** *Complessità variabile delle query.* Il sistema deve supportare la generazione di query di complessità variabile, dal caso di un singolo vincolo su una singola proprietà fino a query che attraversano più relazioni e combinano più vincoli sullo stesso nodo.

3.4 Requisiti non funzionali

I requisiti non funzionali riguardano invece proprietà trasversali del sistema, non direttamente osservabili nel singolo output prodotto.

- RNF1** *Sostenibilità computazionale.* Il sistema deve garantire un tasso di accettazione delle generazioni sufficientemente elevato da rendere il processo economicamente sostenibile in termini di tempo di calcolo.
- RNF2** *Riproducibilità in caso di interruzione.* Il sistema deve essere in grado di riprendere una generazione interrotta senza ripetere il lavoro già completato.

RNF3 *Robustezza semantica.* Il sistema deve limitare il rischio che la variazione linguistica modifichi, senza rilevarlo, il significato della domanda rispetto alla query sottostante, con particolare attenzione ai valori clinici controllati.

Nota *La robustezza semantica riguarda quindi la fedeltà del contenuto, mentre la tracciabilità di O3 riguarda la provenienza e l'associazione tra testo e query.*

Chapter 4

Progettazione

4.1 Analisi dei problemi

I requisiti e i vincoli descritti nel capitolo precedente si traducono in tre sotto-problemi progettuali distinti, la cui interazione determina la difficoltà complessiva del compito. La distinzione è utile perché consente di separare le difficoltà legate alla costruzione delle query da quelle introdotte dalla variazione linguistica e, infine, dalla necessità di verificare gli output prodotti.

P1 *Sotto-problema combinatorio.* Dato lo schema del knowledge graph, generare query SPARQL sintatticamente corrette che coprano una distribuzione rappresentativa dell'uso reale del sistema, senza produrre un numero di combinazioni non gestibile nei tempi o eccessivo per un corretto fine-tuning.

P2 *Sotto-problema linguistico.* Dato un prompt in forma template privo di variazione, generare un numero variabile di parafrasi che siano al tempo stesso fluenti in linguaggio naturale e fedeli al contenuto semantico della query sottostante. A differenza di P1, qui la difficoltà non risiede nella dimensione dello spazio delle soluzioni possibili, ma nell'assenza di un criterio puramente formale per distinguere una parafrasi corretta da una scorretta. Una parafrasi può infatti essere grammaticalmente ineccepibile e superare ogni controllo meccanico applicabile, e tuttavia alterare il significato della domanda originale.

P3 *Sotto-problema di validazione.* Distinto da P1 e P2 ma dipendente da entrambi: verificare, per ciascuna variante generata, che la relazione con la query associata sia corretta e che il contenuto semantico non sia stato alterato durante la variazione linguistica. La tracciabilità richiesta da O3 è una proprietà verificabile della provenienza del dato; la robustezza semantica di RNF3 introduce invece una difficoltà ulteriore, poiché non esiste un criterio puramente formale che stabilisca con certezza l'equivalenza tra una formulazione in linguaggio naturale e la rappresentazione SPARQL sottostante. P3 è quindi il punto in cui la pipeline deve combinare controlli strutturali e semantici, ed è discusso nel dettaglio nel capitolo di valutazione.

I tre sotto-problemi individuati nell'analisi vengono affrontati da componenti distinti della pipeline. P1 è affrontato attraverso il generatore parametrico di query, che consente di controllare lo spazio delle configurazioni esplorate. P2 è affrontato attraverso la fase di augmentation linguistica, progettata per produrre formulazioni diverse a partire dalla medesima query. P3 richiede invece una fase di validazione, che verifica gli output prodotti dalle fasi precedenti prima del loro inserimento nel dataset.

4.2 Design del generatore

Questa sezione descrive le decisioni progettuali alla base del primo stadio del sistema, responsabile della generazione strutturata delle coppie prompt-query.

4.2.1 Modello del dominio

Il modello di dominio di questo progetto non coincide con l'intero schema del knowledge graph del Cancer Virtual Lab, ma con un sottoinsieme di 45 classi fornito dall'IRST. La selezione non ha seguito un criterio puramente tecnico, quale l'inclusione di ogni classe disponibile nel triplestore, ma è stata guidata dagli obiettivi clinici definiti a monte del progetto. Questo sottoinsieme, e la struttura relazionale che lo lega, costituisce un dato di fatto imposto dal knowledge graph ricevuto, non una scelta progettuale: le decisioni discusse nel resto di questa sezione

riguardano non quali classi includere, ma come organizzarle e pesarle ai fini della generazione.

Le quarantacinque classi sono organizzate in gruppi di priorità decrescente, come in fig. 4.1, secondo un criterio di distanza strutturale dal nodo Patient. L'adozione di questo criterio risponde a un'osservazione sul dominio applicativo stesso: Patient costituisce la radice naturale del grafo clinico, coerentemente con il modo in cui un clinico formula una domanda, ovvero a partire dal paziente, non da una classe periferica quale può essere un singolo biomarcatore. La distanza dal nodo radice offre, in aggiunta, un criterio oggettivo e calcolabile direttamente dalla struttura del grafo, senza richiedere l'imposizione anticipata di un giudizio soggettivo su quale classe sia più rilevante dal punto di vista clinico. Tale distanza si è inoltre rivelata un proxy efficace per la complessità della query generabile: una classe raggiungibile con un solo passaggio relazionale produce tipicamente domande semplici e dirette, mentre una classe raggiungibile con due o tre passaggi richiede query che concatenano più relazioni, rendendo la distanza informativa non solo rispetto alla rilevanza clinica, ma anche rispetto alla difficoltà attesa della domanda-tipo associata a ciascuna classe.

L'assenza di un simile criterio di priorizzazione avrebbe comportato conseguenze dirette sul dataset prodotto, discusse in relazione a O4 nel capitolo di analisi. Trattando le quarantacinque classi come equivalenti, il sistema avrebbe allocato un budget di generazione identico a ciascuna, indipendentemente dalla sua centralità nel dominio clinico. Classi concettualmente centrali, quali Patient, Diagnosis e Therapy, avrebbero ricevuto una rappresentazione insufficiente rispetto alla frequenza con cui compaiono nell'uso reale, mentre classi periferiche e altamente granulari, quali le singole categorie della classificazione TNM, avrebbero prodotto un numero di esempi ridondante rispetto alla loro effettiva rilevanza. Il risultato atteso di un simile sbilanciamento non sarebbe stato un dataset semplicemente meno efficiente, ma un modello allenato su di esso incline a generalizzare peggio proprio sulle categorie di domande più frequenti nell'uso previsto del sistema.

La distanza dal nodo Patient non costituisce l'unico criterio di raggruppamento adottato nel corso del progetto. Un secondo raggruppamento, tematico anziché strutturale, organizza le medesime quarantacinque classi per area clinica (demografia, stadiazione, trattamento, ecc.) ed è stato introdotto in una fase suc-

cessiva del progetto, discussa nel capitolo di implementazione. I due criteri non sono stati concepiti come alternativi, ma come complementari; di fatti la distanza strutturale fornisce una progressione di complessità pulita, adatta a un primo passaggio di generazione, mentre il raggruppamento tematico ricombina le stesse classi secondo relazioni di co-occorrenza diverse, consentendo a un secondo passaggio di generazione di produrre query multi-relazionali strutturalmente nuove, anziché ricampionare gli stessi pattern già coperti dal primo raggruppamento.




Figure 4.1: Modello di dominio semplificato: Patient come nodo centrale, con una classe rappresentativa per ciascuno dei sei gruppi di priorità

Il numero di record generati per ciascun gruppo decresce dal centro alla periferia del dominio ma tale decrescita non segue una progressione lineare rigida. Questo andamento è coerente con una calibrazione empirica, ovvero condotta bilanciando l'equilibrio finale del dataset, piuttosto che con l'applicazione di una formula matematica definita anticipatamente. Lo stesso principio di calibrazione empirica viene applicato al sistema dei quattro parametri descritto nella sezione seguente.

In sintesi, il dataset text-to-SPARQL prodotto da questo sistema non è generato in modo uniforme sull'intero schema disponibile, ma segue una gerarchia di rilevanza clinica propria del progetto. Le classi incluse e i parametri di complessità applicati a ciascuna sono stati scelti con l'obiettivo di riflettere le tipologie di domande ritenute più rilevanti nel contesto del Cancer Virtual Lab, privilegiando la rilevanza del dominio rispetto alla massimizzazione della copertura formale del grafo.

4.2.2 Sistema dei parametri

Il modello di dominio descritto nella sezione precedente definisce quali classi partecipano alla generazione e con quale peso relativo, ma non specifica in alcun modo la complessità delle singole query generabili su ciascuna di esse.

Il generatore espone quattro parametri indipendenti, ciascuno regolabile entro un intervallo minimo e massimo, la cui combinazione determina la complessità della query risultante:

- il numero di relazioni attraversate nel grafo a partire dal nodo radice;
- il numero di percorsi alternativi combinati nella medesima query tramite clausole di disgiunzione;
- il numero di proprietà vincolate su un medesimo nodo;
- il numero di valori ammessi per ciascun vincolo.

Questi quattro parametri corrispondono a dimensioni strutturalmente distinte lungo cui una query SPARQL può crescere in complessità. La loro separazione consente di variare un aspetto della complessità senza doverlo necessariamente far crescere insieme agli altri. Trattare la complessità come una singola grandezza scalare avrebbe nascosto questa distinzione, impedendo un controllo mirato su quale aspetto specifico della query si desidera far variare per una determinata classe o gruppo di classi.




Figure 4.2: Modello esemplificativo dei parametri filtrabili

Sebbene l'impianto concettuale dei quattro parametri sia rimasto invariato nel corso del progetto, i valori numerici effettivamente assegnati a ciascuno di essi non sono stati definiti una sola volta, ma calibrati progressivamente attraverso diverse configurazioni successive, tutte vincolate da un limite superiore imposto dall'endpoint SPARQL stesso. Infatti query eccessivamente complesse, al crescere del numero di relazioni e proprietà vincolate simultaneamente, incorrevano in timeout o fallivano l'esecuzione contro il triplestore reale, rendendo necessario mantenere ciascun parametro entro un tetto massimo compatibile con le capacità dell'endpoint.

4.2.3 Meccanismo di estensione

Il sistema di parametri descritto nella sezione precedente offre, come conseguenza diretta della sua struttura, una capacità che va oltre la sola configurazione iniziale della complessità: la possibilità di ampliare il dataset generato senza rigenerare le porzioni già prodotte, e senza il rischio che le nuove query si sovrappongano a quelle esistenti.

Questa capacità è resa possibile dal fatto che un intervallo minimo-massimo definisce uno spazio di configurazioni delimitato con precisione. Impostando, per un nuovo preset di generazione, un intervallo disgiunto da quello di un preset precedente su almeno una dimensione rilevante, i due spazi risultano disgiunti a livello di configurazione dei parametri. In questo modo il nuovo preset esplora combinazioni che non appartenevano allo spazio configurato in precedenza. La proprietà è quindi garantita a livello parametrico; l'assenza di duplicati a livello di query è invece una proprietà che dipende dal modo in cui le configurazioni vengono trasformate in query e, se necessario, può essere verificata esplicitamente durante la generazione.

Questa distinzione rende il meccanismo di estensione più preciso: l'aggiunta di nuove porzioni al dataset non richiede una riprogettazione del generatore, ma la definizione di nuovi preset i cui intervalli siano scelti in relazione a quelli già utilizzati. La procedura può essere applicata ripetutamente, mantenendo traccia dello spazio parametrico già esplorato e introducendo nuove configurazioni al di fuori di esso.

4.3 Design dell'augmentation

Questa sezione descrive le decisioni progettuali alla base del secondo stadio del sistema, responsabile della trasformazione delle coppie prompt-query prodotte dal generatore in più varianti linguistiche naturali, secondo il compromesso tra varietà e fedeltà semantica richiesto da O2 e la robustezza semantica richiesta da RNF3.

4.3.1 Mascheramento dei valori letterali

Il problema affrontato da questo stadio è duplice: da un lato produrre varie riformulazioni linguisticamente a partire da uno stesso prompt, dall'altro garantire che tale variazione non alteri i valori letterali che compaiono nel prompt e che sono referenziati dalla query SPARQL associata (identificativi, codici di classificazione clinica, date). Lasciare che un modello linguistico riscriva liberamente l'intero testo, valori inclusi, esporrebbe il sistema al rischio già discusso in RF3 e RNF3, ovvero una riformulazione apparentemente valida ma silenziosamente scorretta rispetto alla query originale.

La soluzione adottata separa la variazione linguistica dai valori da preservare tramite un meccanismo di mascheramento. Prima di essere sottoposto al modello, ogni valore letterale identificato nel prompt viene sostituito da un token segnaposto opaco; il modello riformula quindi il testo mascherato, e solo al termine della generazione i segnaposto vengono sostituiti nuovamente con i valori originali. In questo modo il modello non ha mai accesso al valore letterale reale durante la riformulazione, e può quindi soltanto ricollocarlo all'interno di una struttura sintattica diversa.

Sono stati introdotti inoltre due accorgimenti specifici per la gestione dei valori mascherati. Il primo riguarda quando un segnaposto rappresenta una condizione vera o falsa, come la presenza di un evento avverso; in questo caso il valore non viene mantenuto nella forma letterale *true* o *false*, ma viene convertito in una formulazione più naturale per il linguaggio umano, come «con» o «senza», seguita dal termine clinico corrispondente.

Il secondo accorgimento riguarda i record caratterizzati da un numero elevato di valori mascherati. In questi casi, il testo non viene sottoposto al modello attraverso

un'unica chiamata, ma viene suddiviso in più porzioni, ciascuna contenente al massimo un numero prefissato di segnaposto. Le singole porzioni vengono quindi riformulate separatamente e ricomposte al termine della generazione. Questa scelta deriva da un'osservazione empirica secondo cui, oltre una determinata soglia di segnaposto presenti nello stesso prompt, la qualità delle riformulazioni generate tende a diminuire.

4.3.2 Generazione iterativa e validazione

Il mascheramento garantisce che i valori letterali, se presenti nell'output, siano corretti; non garantisce però che il modello produca sempre un output valido al primo tentativo, né che varianti successive dello stesso record non finiscano per ripetersi tra loro, vanificando l'obiettivo di varietà linguistica di O2.

Il sistema affronta questo problema attraverso un ciclo iterativo di generazione e verifica. Ogni candidato prodotto dal modello viene sottoposto a una fase di validazione che considera diversi criteri.

- **Preservazione dei segnaposto.** Il candidato viene rifiutato se anche un solo segnaposto è stato omissso, modificato o sostituito.
- **Assenza di segnaposto non previsti.** Viene verificato che il testo non contenga sequenze che imitano la sintassi di un segnaposto senza corrispondere a uno dei segnaposto effettivamente presenti nel testo originale.
- **Controllo della similarità.** Il candidato viene confrontato con le varianti già accettate per lo stesso record. Se risulta eccessivamente simile a una di esse, viene rifiutato. La soglia di similarità viene resa progressivamente più permissiva al diminuire della lunghezza del testo, così da evitare che formulazioni brevi vengano considerate erroneamente come duplicati.

In caso di rifiuto, il sistema non si limita a ripetere la generazione. Il candidato scartato e il relativo motivo vengono forniti al modello come contesto aggiuntivo per il tentativo successivo, in modo da ridurre la probabilità che venga ripetuto lo stesso errore. A ogni nuovo tentativo viene inoltre incrementata progressivamente

la temperatura di campionamento, favorendo la produzione di una formulazione diversa da quella precedente.

Se anche l'ultimo tentativo disponibile viene rifiutato, il sistema non forza comunque l'inserimento di una nuova variante. Viene invece mantenuto il testo originale non modificato e viene registrato esplicitamente il ricorso a questo comportamento di ripiego. In questo modo si evita di accettare silenziosamente una formulazione che violi i vincoli definiti da RF3 o RNF3.

Il numero di varianti richieste per ciascun record non è inoltre fissato in modo uniforme, ma proporzionato al numero di valori mascherati nel record: un prompt con pochi valori offre in pratica poco margine di riformulazione prima di esaurire le combinazioni naturali, per cui imporre lo stesso numero di varianti richieste a un record semplice e a uno complesso avrebbe prodotto, nel primo caso, un'alta proporzione di tentativi rifiutati per eccessiva similarità.

4.3.3 Varietà stilistica

Il solo mascheramento non garantisce, di per sé, la varietà linguistica richiesta da O2: un modello lasciato libero di riformulare tende a convergere su un piccolo numero di strutture sintattiche ricorrenti. Il sistema affronta questo problema definendo un insieme di dieci registri stilistici predefiniti (ad esempio una formulazione tecnica in stile interrogazione a database, una clinico-formale, una colloquiale, una statistica orientata al conteggio), esplicitamente descritti al modello a ogni chiamata.

Gli stili non vengono assegnati alle varianti in modo casuale, ma percorsi in sequenza ciclica, in modo che la distribuzione degli stili sulle varianti generate risulti uniforme anziché soggetta alla variabilità di un'estrazione casuale. Per ciascuno stile, il sistema mantiene inoltre una memoria a breve termine delle formulazioni e delle parole di apertura usate più di recente: un nuovo candidato che ripropone un'apertura già usata di recente per lo stesso stile viene rifiutato dalla validazione allo stesso modo di una riformulazione troppo simile a livello di intero testo, estendendo così il controllo di varietà anche alla struttura delle prime parole della frase, non solo al suo contenuto complessivo.

Il sistema conserva infine, per ciascun record, anche una modalità alternativa

priva di mascheramento, che riproduce il comportamento originario a chiamata singola sull'intero testo. Questa modalità non costituisce un secondo percorso di produzione, ma un termine di paragone esplicito, i cui risultati sono discussi assieme a quelli della modalità con mascheramento nel capitolo di valutazione.

Chapter 5

Implementazione

Chapter 6

Valutazione

Chapter 7

Conclusioni e sviluppi futuri

Acknowledgements

la vuoi