

Corso di Laurea in Ingegneria e Scienze Informatiche

**Generazione automatica di dataset
text-to-SPARQL per fine-tuning di
LLM su knowledge graph
clinico-oncologico**

Tesi di laurea in:
PROGRAMMAZIONE

Relatore

Prof.ssa Antonella Carbonaro

Candidato

Matteo Tonelli

Abstract

Contents

Abstract	iii
1 Introduction	1
2 Background	3
3 Analysis	7
3.1 High-level goals	7
3.2 Constraints	7
3.3 Functional and non-functional requirements	7
3.4 Domain model	7
4 Design	9
4.1 Architecture	9
4.2 Detailed design	9
5 Implementation	11
5.1 Technology stack	11
5.2 Implementation highlights	11
6 Evaluation	13
6.1 Methodology	13
6.2 Quality issues found	13
6.3 Dataset statistics	13
7 Conclusion and Future Work	15
	17
Bibliography	17

CONTENTS

List of Figures

LIST OF FIGURES

List of Listings

LIST OF LISTINGS

Chapter 1

Introduction

Structure of the Thesis

Chapter 2

Background

Un knowledge graph è una rappresentazione strutturata della conoscenza in cui le entità del dominio (pazienti, diagnosi, terapie, nel caso del Cancer Virtual Lab) sono modellate come nodi, e le relazioni tra esse come archi etichettati. Questa rappresentazione segue tipicamente il modello RDF (*Resource Description Framework*), in cui ogni fatto è espresso come una tripla soggetto-predicato-oggetto, ad esempio un paziente collegato a una diagnosi tramite la relazione `has_diagnosis`.

SPARQL è il linguaggio di interrogazione standard per dati RDF, analogo per ruolo a SQL nel contesto delle basi di dati relazionali. Una query SPARQL specifica un pattern di triple da individuare nel grafo, con la possibilità di applicare filtri sui valori e vincoli sulla struttura delle relazioni attraversate.

Il problema del text-to-SPARQL si inserisce in una famiglia più ampia di compiti noti in letteratura come semantic parsing, in cui un sistema deve tradurre un enunciato in linguaggio naturale in una rappresentazione formale eseguibile. Nel caso specifico del text-to-SQL e del text-to-SPARQL, la rappresentazione target è un linguaggio di interrogazione strutturato, e la difficoltà principale risiede nella necessità di colmare il divario tra la libertà espressiva del linguaggio naturale e la rigidità sintattica e semantica del linguaggio target. Un modello deve non solo comprendere l'intento della domanda, ma anche conoscere con precisione lo schema sottostante, ovvero i nomi delle entità, delle proprietà e delle relazioni disponibili, poiché un errore anche minimo nella scelta di un predicato produce una query sintatticamente valida ma semanticamente errata.

Nel dominio specifico del text-to-SPARQL su knowledge graph clinici, questa difficoltà è accentuata da due fattori. In primo luogo, lo schema è spesso altamente specialistico e non presente nella conoscenza pregressa di un modello linguistico generalista, che non ha modo di conoscere a priori l'esistenza di una proprietà come `has_ECOG_status` o di un'entità come *Pathological TNM*. In secondo luogo, la scarsità di dati annotati è un problema ricorrente in ambito clinico, dove la produzione di coppie domanda-query richiede competenze di dominio che non tutti gli annotatori possiedono.

Diversi lavori in letteratura hanno affrontato il problema della costruzione di dataset per il text-to-SPARQL, adottando strategie differenti per generare la componente in linguaggio naturale a partire da query strutturate. LC-QuAD, nelle sue due versioni [TMDL17, DBAL19], costruisce le domande a partire da template applicati al grafo, genera una domanda intermedia in linguaggio quasi naturale (NNQT, *Normalized Natural Question Template*) e infine affida a annotatori umani, tramite piattaforme di crowdsourcing, la parafrasi finale in linguaggio naturale fluente, producendo una singola parafrasi per ciascuna domanda. MK-SQuIT [SCKS20] adotta invece un approccio interamente automatico, generando sia la query sia la sua controparte testuale tramite una grammatica formale, senza alcuna fase di parafrasi successiva: la variabilità linguistica del dataset dipende quindi unicamente dalla ricchezza della grammatica stessa. Un lavoro più recente di IBM Research, condotto da Bulle Labate e colleghi [LdCF25], applica invece un modello linguistico di grandi dimensioni per rigenerare le parafrasi delle domande già presenti in LC-QuAD, validando la qualità del risultato tramite un secondo modello linguistico nel ruolo di giudice, secondo cinque criteri valutati su una scala da uno a cinque.

Questi tre lavori delineano uno spettro di possibili approcci: da un estremo interamente manuale nella fase di parafrasi, a un estremo interamente automatico privo di parafrasi, fino a un approccio ibrido in cui l'automazione tramite modello linguistico sostituisce l'annotatore umano pur mantenendo una fase di parafrasi esplicita. L'utilizzo di modelli linguistici per l'augmentation testuale non è tuttavia privo di rischi, in particolare quando applicato a domini con vocabolario controllato: un modello può introdurre sinonimi lessicalmente plausibili ma semanticamente non equivalenti al termine originale, alterando il significato clinico

di un valore senza che questo risulti evidente da un controllo superficiale del testo prodotto.

Il lavoro descritto in questa tesi si colloca in prossimità dell'estremo automatico dello spettro appena descritto, condividendo con MK-SQuIT l'assenza di annotazione umana nella fase di parafrasi, ma introducendo, a differenza di quest'ultimo, una fase di validazione programmatica multilivello sull'output del modello linguistico, distinta sia dall'approccio di IBM Research, che affida la validazione a un secondo modello linguistico, sia dall'assenza di validazione esplicita in MK-SQuIT.

Le tecniche di augmentation testuale basate su modelli linguistici di grandi dimensioni si sono affermate come alternativa alla parafrasi manuale in numerosi compiti di elaborazione del linguaggio naturale, sfruttando la capacità di questi modelli di produrre riformulazioni fluenti e grammaticalmente corrette a partire da un testo sorgente. Rispetto a tecniche più risalenti, come la sostituzione di sinonimi tramite risorse lessicali statiche o la back-translation attraverso un sistema di traduzione automatica, un modello linguistico generativo consente una variazione più ampia nella struttura sintattica e nel registro della frase prodotta, non limitandosi alla sola sostituzione lessicale.

Questa flessibilità comporta tuttavia un rischio strutturale, distinto dal semplice errore casuale: un modello linguistico generalista non possiede, per costruzione, conoscenza affidabile di vocabolari controllati specifici di un dominio, quali codici di classificazione clinica, terminologie normalizzate, o distinzioni concettuali che a un lettore non esperto del dominio possono apparire equivalenti pur non essendolo. Nel richiedere una parafrasi o un sinonimo per un termine di questo tipo, il modello può produrre un'alternativa lessicalmente plausibile ma semanticamente non equivalente, senza segnalare in alcun modo l'incertezza sottostante. Questo comportamento si manifesta tipicamente in due forme distinte. La prima è la sostituzione di un termine tecnico con un termine di registro comune tratto da un dominio concettualmente adiacente ma distinto, che altera il contesto interpretativo del valore pur mantenendone una plausibilità superficiale. La seconda, più marcata, è l'allucinazione vera e propria, in cui il modello associa a un codice o a un identificativo privo di significato lessicale intrinseco un'interpretazione testuale inventata, spesso non verificabile a partire dal solo contesto della frase prodotta.

La rilevanza di questi rischi per un dataset destinato al fine-tuning non si limita alla qualità percepita del singolo esempio generato: un modello allenato su dati contenenti sostituzioni sistematicamente errate rischia di apprendere associazioni scorrette tra forma linguistica e significato clinico, propagando l'errore oltre il singolo esempio da cui ha avuto origine. Per questa ragione, l'adozione di tecniche di augmentation basate su modelli linguistici richiede, più che nei casi in cui il vocabolario di dominio non sia critico, una fase di validazione esplicita dell'output prodotto, distinta dalla sola verifica di correttezza grammaticale o di fluidità superficiale della frase.

Nel capitolo dedicato alla valutazione del dataset prodotto in questo lavoro (chapter 6) sono documentati casi concreti riconducibili a entrambe le forme di errore appena descritte, insieme alla metodologia adottata per individuarli e alle correzioni apportate al sistema di generazione delle parafrasi.

In sintesi, il presente lavoro si colloca in un punto specifico dello spettro delineato dai tre approcci discussi: automatico nella generazione della componente strutturata e nella parafrasi, come MK-SQuIT, ma dotato di un meccanismo di validazione esplicito e multilivello che né MK-SQuIT né, in forma diversa, IBM Research adottano nella medesima misura. I capitoli successivi descrivono nel dettaglio l'architettura adottata (chapter 4), la sua implementazione (chapter 5), e i risultati della validazione condotta sul dataset prodotto (chapter 6).

Chapter 3

Analysis

3.1 High-level goals

3.2 Constraints

3.3 Functional and non-functional requirements

3.4 Domain model

Chapter 4

Design

4.1 Architecture

4.2 Detailed design

Chapter 5

Implementation

5.1 Technology stack

5.2 Implementation highlights

Chapter 6

Evaluation

6.1 Methodology

6.2 Quality issues found

6.3 Dataset statistics

Chapter 7

Conclusion and Future Work

Bibliography

- [DBAL19] Mohnish Dubey, Debayan Banerjee, Abdelrahman Abdelkawi, and Jens Lehmann. Lc-quad 2.0: A large dataset for complex question answering over wikidata and dbpedia. In *The Semantic Web – ISWC 2019*, pages 69–78. Springer, 2019.
- [LdCF25] A. B. Labate, B. W. S. R. de Carvalho, and S. R. Fiorini. Synthetic dataset generation and validation with LLMs for text2sparql in Wikidata graphs. In *Proceedings of the Wikidata Workshop 2025*, 2025.
- [SCKS20] B. A. Spiegel, V. Cheong, J. E. Kaplan, and A. Sanchez. MK-SQuIT: Synthesizing questions using iterative template-filling, 2020.
- [TMDL17] Priyansh Trivedi, Gaurav Maheshwari, Mohnish Dubey, and Jens Lehmann. Lc-quad: A corpus for complex question answering over knowledge graphs. In *The Semantic Web – ISWC 2017*, pages 210–218. Springer, 2017.

Acknowledgements